

# Covarianza

En Espacios muestrales bidimensionales es interesante analizar la relación entre ambas variables.

**La COVARIANZA** es una medida de asociación o dependencia entre 2 variables aleatorias. La covarianza puede ser positiva o negativa (la varianza siempre es positiva). Si valores grandes de  $X$  a menudo dan como resultado valores grandes de  $Y$ , o valores pequeños de  $X$ , dan como resultado valores pequeños de  $Y$ , la covarianza será positiva. Caso contrario será negativa.

Si  $X$  e  $Y$  son variables aleatorias con función de distribución conjunta (fdc),  $f_{x,y}(x, y)$ , para el caso discreto (VAD) o función de densidad de probabilidad conjunta (fdpc) para el caso continuo (VAC), entonces la covarianza de  $(x, y)$  ó  $COV(x, y) = \sigma_{xy}$  es:

$$\sigma_{xy} = E[(x - \mu_x) \cdot (y - \mu_y)]$$

$$\sigma_{xy} = E[(x - \mu_x) \cdot (y - \mu_y)]$$

$$\sigma_{xy} = \sum_x \sum_y (x - \mu_x) \cdot (y - \mu_y) \cdot f_{x,y}(x, y) \quad \text{VAD}$$

$$\sigma_{xy} = \int_{y=-\infty}^{+\infty} \int_{x=-\infty}^{+\infty} (x - \mu_x) \cdot (y - \mu_y) \cdot f_{x,y}(x, y) dx dy \quad \text{VAC}$$

Una fórmula alternativa de cálculo de COV es:

$$\sigma_{xy} = E(xy) - \mu_x \cdot \mu_y$$

Donde, por definición del operador Esperanza:  $E[Y] = \int_{-\infty}^{+\infty} Y \cdot f(x) dx$

$$E(xy) \quad \longrightarrow \quad E(xy) = \int_{y=-\infty}^{+\infty} \int_{x=-\infty}^{+\infty} x \cdot y \cdot f_{x,y}(x, y) dx dy$$

Demostrar la fórmula alternativa de la *COV*:  
para el caso continuo:

$$\sigma_{xy} = E(xy) - \mu_x \cdot \mu_y$$

Partamos de la definición de *COV*:  $\sigma_{xy} = E[(x - \mu_x) \cdot (y - \mu_y)]$  que para una VAC:

$$\sigma_{xy} = \int_{y=-\infty}^{+\infty} \int_{x=-\infty}^{+\infty} (x - \mu_x) \cdot (y - \mu_y) \cdot f_{x,y}(x, y) dx dy$$

¿Qué hacemos ahora?



Apliquemos propiedad distributiva

$$\sigma_{xy} = \int_{y=-\infty}^{y=\infty} \int_{x=-\infty}^{x=\infty} [x \cdot y \cdot f_{x,y}(x, y) - \mu_x \cdot y \cdot f_{x,y}(x, y) - x \cdot \mu_y \cdot f_{x,y}(x, y) + \mu_x \cdot \mu_y \cdot f_{x,y}(x, y)] dx dy$$

Demostrar la fórmula alternativa de la *COV*:  
para el caso continuo:

$$\sigma_{xy} = E(xy) - \mu_x \cdot \mu_y$$

Partamos de la definición de *COV*:  $\sigma_{xy} = E[(x - \mu_x) \cdot (y - \mu_y)]$  que para una VAC:

$$\sigma_{xy} = \int_{y=-\infty}^{+\infty} \int_{x=-\infty}^{+\infty} (x - \mu_x) \cdot (y - \mu_y) \cdot f_{x,y}(x, y) dx dy$$

¿Qué hacemos ahora?



Apliquemos propiedad distributiva

$$\sigma_{xy} = \int_{y=-\infty}^{y=\infty} \int_{x=-\infty}^{x=\infty} [x \cdot y \cdot f_{x,y}(x, y) - \underline{\mu_x \cdot y \cdot f_{x,y}(x, y)} - x \cdot \underline{\mu_y \cdot f_{x,y}(x, y)} + \mu_x \cdot \mu_y \cdot f_{x,y}(x, y)] dx dy$$

Demostrar la fórmula alternativa de la *COV*:  
para el caso continuo:

$$\sigma_{xy} = E(xy) - \mu_x \cdot \mu_y$$

Partamos de la definición de *COV*:  $\sigma_{xy} = E[(x - \mu_x) \cdot (y - \mu_y)]$  que para una VAC:

$$\sigma_{xy} = \int_{y=-\infty}^{+\infty} \int_{x=-\infty}^{+\infty} (x - \mu_x) \cdot (y - \mu_y) \cdot f_{x,y}(x, y) dx dy$$

¿Qué hacemos ahora?



Apliquemos propiedad distributiva

$$\sigma_{xy} = \int_{y=-\infty}^{y=\infty} \int_{x=-\infty}^{x=\infty} [x \cdot y \cdot f_{x,y}(x, y) - \underline{\mu_x \cdot y \cdot f_{x,y}(x, y)} - \underline{x \cdot \mu_y \cdot f_{x,y}(x, y)} + \mu_x \cdot \mu_y \cdot f_{x,y}(x, y)] dx dy$$

Demostrar la fórmula alternativa de la *COV*:  
para el caso continuo:

$$\sigma_{xy} = E(xy) - \mu_x \cdot \mu_y$$

Partamos de la definición de *COV*:  $\sigma_{xy} = E[(x - \mu_x) \cdot (y - \mu_y)]$  que para una VAC:

$$\sigma_{xy} = \int_{y=-\infty}^{+\infty} \int_{x=-\infty}^{+\infty} (x - \mu_x) \cdot (y - \mu_y) \cdot f_{x,y}(x, y) dx dy$$

¿Qué hacemos ahora?



Apliquemos propiedad distributiva

$$\sigma_{xy} = \int_{y=-\infty}^{y=\infty} \int_{x=-\infty}^{x=\infty} [x \cdot y \cdot f_{x,y}(x, y) - \underline{\mu_x \cdot y \cdot f_{x,y}(x, y)} - \underline{x \cdot \mu_y \cdot f_{x,y}(x, y)} + \underline{\mu_x \cdot \mu_y \cdot f_{x,y}(x, y)}] dx dy$$

¿Y ahora?

Separaremos en varias integrales distribuyendo en los términos del integrando

$$\sigma_{xy} = \int_{y=-\infty}^{y=\infty} \int_{x=-\infty}^{x=\infty} [x \cdot y \cdot f_{x,y}(x, y) - \mu_x \cdot y \cdot f_{x,y}(x, y) - x \cdot \mu_y \cdot f_{x,y}(x, y) + \mu_x \cdot \mu_y \cdot f_{x,y}(x, y)] dx dy$$

sabiendo que  $\mu_x$  y  $\mu_y$  son constantes ya que son los promedios poblacionales:

$$\sigma_{xy} = \frac{\int_{y=-\infty}^{y=\infty} \int_{x=-\infty}^{x=\infty} x \cdot y \cdot f_{x,y}(x, y) dx dy - \mu_x \int_{y=-\infty}^{y=\infty} \int_{x=-\infty}^{x=\infty} y \cdot f_{x,y}(x, y) dx dy}{1} \quad 2$$

$$- \mu_y \int_{y=-\infty}^{y=\infty} \int_{x=-\infty}^{x=\infty} x \cdot f_{x,y}(x, y) dx dy + \mu_x \cdot \mu_y \int_{y=-\infty}^{y=\infty} \int_{x=-\infty}^{x=\infty} f_{x,y}(x, y) dx dy \quad 3 \quad 4$$

$$1 \quad E(xy) = \int_{y=-\infty}^{+\infty} \int_{x=-\infty}^{+\infty} x \cdot y \cdot f_{x,y}(x, y) dx dy$$

$$2 \quad \text{Como: } \int_{x=-\infty}^{x=\infty} f_{x,y}(x, y) dx = h(y) \rightarrow \text{Función marginal de } Y$$

$$\int_{y=-\infty}^{y=\infty} \int_{x=-\infty}^{x=\infty} y \cdot f_{x,y}(x, y) dx dy = \int_{y=-\infty}^{y=\infty} y \cdot h(y) dy = E(y) = \mu_y$$

$$\sigma_{xy} = \int_{y=-\infty}^{y=\infty} \int_{x=-\infty}^{x=\infty} [x \cdot y \cdot f_{x,y}(x, y) - \mu_x \cdot y \cdot f_{x,y}(x, y) - x \cdot \mu_y \cdot f_{x,y}(x, y) + \mu_x \cdot \mu_y \cdot f_{x,y}(x, y)] dx dy$$

sabiendo que  $\mu_x$  y  $\mu_y$  son constantes ya que son los promedios poblacionales:

$$\begin{aligned} \sigma_{xy} &= \frac{\int_{y=-\infty}^{y=\infty} \int_{x=-\infty}^{x=\infty} x \cdot y \cdot f_{x,y}(x, y) dx dy}{1} - \mu_x \frac{\int_{y=-\infty}^{y=\infty} \int_{x=-\infty}^{x=\infty} y \cdot f_{x,y}(x, y) dx dy}{2} \\ &\quad - \mu_y \frac{\int_{y=-\infty}^{y=\infty} \int_{x=-\infty}^{x=\infty} x \cdot f_{x,y}(x, y) dx dy}{3} + \mu_x \cdot \mu_y \frac{\int_{y=-\infty}^{y=\infty} \int_{x=-\infty}^{x=\infty} f_{x,y}(x, y) dx dy}{4} \end{aligned}$$

3 De igual forma que en el caso anterior:  $\int_{x=-\infty}^{x=\infty} \int_{y=-\infty}^{y=\infty} x \cdot f_{x,y}(x, y) dy dx = E(x) = \mu_x$

4 Y la integral doble:  $\int_{-\infty}^{\infty} \int_{-\infty}^{\infty} f_{x,y}(x, y) dx dy = 1$

Reemplazando estos valores en la función anterior nos queda:

$$\begin{aligned} \sigma_{xy} &= \int_{y=-\infty}^{y=\infty} \int_{x=-\infty}^{x=\infty} x \cdot y \cdot f_{x,y}(x, y) dx dy - \mu_x \int_{y=-\infty}^{y=\infty} \int_{x=-\infty}^{x=\infty} y \cdot f_{x,y}(x, y) dx dy \\ &\quad - \mu_y \int_{y=-\infty}^{y=\infty} \int_{x=-\infty}^{x=\infty} x \cdot f_{x,y}(x, y) dx dy + \mu_x \cdot \mu_y \int_{y=-\infty}^{y=\infty} \int_{x=-\infty}^{x=\infty} f_{x,y}(x, y) dx dy \\ &\quad = 1 \\ \sigma_{xy} &= E(xy) - \mu_x \cdot \mu_y - \mu_y \cdot \mu_x + \mu_x \cdot \mu_y \end{aligned}$$

El signo de la covarianza indica la relación directa (+) o inversa (-) entre  $X$  e  $Y$ . Si son estadísticamente independientes, la covarianza dará 0. Lo opuesto no es necesariamente cierto, es decir si la Covarianza da 0 no necesariamente son estadísticamente independientes. La covarianza sólo describe la relación lineal entre dos variables aleatorias, por consiguiente, si una covarianza entre  $X$  e  $Y$  es cero pero  $X$  e  $Y$  no tienen una relación lineal, no significa que son independientes. Serán independientes en el caso que la fdp o fdpc sean de carácter lineal.

Ejemplo: Sea  $X$  el tiempo de reacción, en segundos, de dos componentes químicos e  $Y$  la temperatura (en °C) a la cual inicia la reacción. Suponga que las dos variables aleatorias,  $X$  e  $Y$ , tienen la densidad conjunta:

$$f(x, y) = \begin{cases} 4xy & \text{para } 0 \leq x \leq 1; 0 \leq y \leq 1 \\ 0 & \text{para otro caso} \end{cases}$$

Determine si esta fdpc es válida. En caso afirmativo, calcule la  $COV$  entre  $X$  e  $Y$  para determinar si existe relación entre la velocidad de reacción y la temperatura y si la misma es directa o inversa.

Solución:

a)  $f(x, y) \geq 0 ; \forall (x, y)$

b)  $\int_{y=-\infty}^{+\infty} \int_{x=-\infty}^{+\infty} f(x, y) dx dy =$

$$= 4 \int_{y=0}^1 \int_{x=0}^1 xy dx dy = 4 \int_{y=0}^1 y \frac{x^2}{2} \Big|_0^1 dy = 2 \int_{y=0}^1 y dy = 2 \frac{y^2}{2} \Big|_0^1 = 1 \quad \checkmark$$

$$\sigma_{xy} = E(xy) - \mu_x \cdot \mu_y$$

$$E(xy) = \int_{y=-\infty}^{+\infty} \int_{x=-\infty}^{+\infty} xy \cdot f_{x,y}(x, y) dx dy = \int_{y=0}^1 \int_{x=0}^1 xy \cdot 4xy dx dy$$

$$E(xy) = 4 \int_{y=0}^1 \int_{x=0}^1 x^2 y^2 dx dy = 4 \int_{y=0}^1 y^2 \frac{x^3}{3} \Big|_0^1 dy = 4 \int_{y=0}^1 y^2 \frac{1}{3} dy = \frac{4}{3} \frac{y^3}{3} \Big|_0^1 = \frac{4}{9}$$

$$\mu_x = E(x) = \int_{x=-\infty}^{+\infty} x g(x) dx \quad \text{con} \quad g(x) = \int_{y=-\infty}^{+\infty} f_{x,y}(x, y) dy = 4x \int_{y=0}^1 y dy = 2x$$

$$\mu_x = E(x) = \int_{x=-\infty}^{+\infty} x g(x) dx = 2 \int_{x=0}^1 x^2 dx = \frac{2}{3}$$

$$\mu_y = E(y) = \int_{y=-\infty}^{+\infty} y h(y) dy = 2 \int_{y=0}^1 y^2 dy = \frac{2}{3}$$

$$\sigma_{xy} = E(xy) - \mu_x \cdot \mu_y = \frac{4}{9} - \frac{2}{3} \cdot \frac{2}{3} = 0$$

Como sabemos que la fdpc es de carácter lineal,  $f(x, y) = 4xy$ , entonces podemos decir que las variables  $X$  e  $Y$  son independientes.

Ejemplo: El número de repuestos de bolígrafos azules  $X$  y el número de repuestos de bolígrafos rojos  $Y$  se encuentran en una caja para la venta. Cuando se seleccionan dos repuestos para bolígrafo al azar se obtiene la distribución de probabilidad conjunta siguiente:

$f(x,y)$		$X$			$h(y)$
		0	1	2	
$Y$	0	3/28	9/28	3/28	15/28
	1	3/14	3/14	0	3/7
	2	1/28	0	0	1/28
$g(x)$		5/14	15/28	3/28	1

Calcule la covarianza de  $X$  e  $Y$

Solución:  $\sigma_{xy} = E(xy) - \mu_x \cdot \mu_y$

$$E(xy) = \sum_x \sum_y x \cdot y \cdot f(x, y) = \frac{3}{14}$$

$$\mu_x = E(x) = \sum_x x \cdot g(x) = (0) \cdot \frac{5}{14} + (1) \cdot \frac{15}{28} + (2) \cdot \frac{3}{28} = \frac{21}{28} = \frac{3}{4}$$

$$\mu_y = E(y) = \sum_y y \cdot h(y) = (0) \cdot \frac{15}{28} + (1) \cdot \frac{3}{7} + (2) \cdot \frac{1}{28} = \frac{14}{28} = \frac{1}{2}$$

$$\sigma_{xy} = \frac{3}{14} - \frac{3}{4} \cdot \frac{1}{2} = \frac{3}{14} - \frac{3}{8} = \frac{12 - 21}{56} = -\frac{9}{56}$$



De manera tal que si en la extracción se observan más biromes azules se reducirá el número de biromes rojas.

$f(x,y)$		$X$			$h(y)$
		0	1	2	
$Y$	0	$3/28$	$9/28$	$3/28$	$15/28$
	1	$3/14$	$3/14$	0	$3/7$
	2	$1/28$	0	0	$1/28$
$g(x)$		$5/14$	$15/28$	$3/28$	1

# Coeficiente de Correlación

Aunque la covarianza indica el sentido de la dependencia entre  $X$  e  $Y$ , no indica nada al respecto de la fuerza de esta relación, ya que está ligado a las escalas de  $X$  e  $Y$ .

La versión de la covarianza libre de escala se llama “**Coeficiente de correlación**”:

$$\rho_{x,y} = \frac{\sigma_{xy}}{\sigma_x \cdot \sigma_y}$$

Debería quedar claro para el lector que  $\rho_{x,y}$  no tiene las unidades de  $X$  e  $Y$ . El coeficiente de correlación satisface la desigualdad  $-1 \leq \rho_{x,y} \leq 1$ . Toma un valor de cero cuando  $\sigma_{xy} = 0$ .

Ejemplo: Calcule  $\rho_{x,y}$  del ejemplo de los repuestos de bolígrafos.

Solución:  $\rho_{x,y} = \frac{\sigma_{xy}}{\sigma_x \cdot \sigma_y}$  con  $\sigma_{xy} = -\frac{9}{56}$

$$V(x) = \sigma_x^2 = E(x^2) - E(x)^2 = \sum_x x^2 g(x) - \left[ \sum_x x g(x) \right]^2$$

$$\sigma_x^2 = (1)^2 \cdot \frac{15}{28} + (2)^2 \cdot \frac{3}{28} - \left( \frac{3}{4} \right)^2 = \frac{27}{28} - \frac{9}{16} = \frac{45}{112}$$

$$\sigma_y^2 = (1)^2 \cdot \frac{3}{7} + (2)^2 \cdot \frac{1}{28} - \left( \frac{1}{2} \right)^2 = \frac{16}{28} - \frac{1}{4} = \frac{16 - 7}{28} = \frac{9}{28}$$

$$\rho_{x,y} = -\frac{9}{56} \cdot \frac{1}{\sqrt{\left(\frac{45}{112}\right) \cdot \left(\frac{9}{28}\right)}} = -\frac{1}{\sqrt{5}}$$

$$\rho_{x,y} = -0,4472$$

$f(x,y)$		$X$			$h(y)$
		0	1	2	
$Y$	0	3/28	9/28	3/28	15/28
	1	3/14	3/14	0	3/7
	2	1/28	0	0	1/28
$g(x)$		5/14	15/28	3/28	1

# Independencia estadística

Habíamos visto que si  $X$  e  $Y$  son variables aleatorias conjuntas con función de distribución de probabilidad  $f_{x,y}(x,y)$  y si es posible que  $f_{x,y}(x,y)$  puede factorizarse como un producto de las funciones de distribución de probabilidad marginales  $g(x)$  y  $h(y)$ , entonces se dice que  $X$  e  $Y$  son variables aleatorias independientes  $f_{x,y}(x,y) = g(x).h(y)$ .

Podemos deducir entonces que en términos de esperanza  $X$  e  $Y$  podrían ser independientes cuando observamos que un valor aleatorio para  $X$ , podría no influir (o tiene la esperanza de no influir) en los valores aleatorios de  $Y$  si se verifica que:

$$E(xy) = E(x) \cdot E(y)$$

Demostración de:  $E(xy) = E(x).E(y)$  se cumple cuando  $f(x, y) = g(x).h(y)$ , es decir, cuando  $X$  e  $Y$  son independientes.

$$E(xy) = \int_{x=-\infty}^{x=\infty} \int_{y=-\infty}^{y=\infty} x \cdot y \cdot f_{x,y}(x, y) dy dx$$

Si  $X$  e  $Y$  son independientes, entonces sabemos que:  $f_{x,y}(x, y) = g(x) \cdot h(y)$   
Por lo tanto reemplazando:

$$E(xy) = \int_{x=-\infty}^{x=\infty} \int_{y=-\infty}^{y=\infty} x y g(x) h(y) dy dx = \int_{x=-\infty}^{x=\infty} x g(x) dx \cdot \int_{y=-\infty}^{y=\infty} y h(y) dy$$

Entonces:  $E(xy) = E(x).E(y) = \mu_x \cdot \mu_y$

Esta identidad, que es verificada cuando existe independencia, reafirma lo que se postuló respecto de la covarianza:

$$\sigma_{xy} = E(xy) - \mu_x \cdot \mu_y = 0$$

ya que  $X$  e  $Y$  son independientes

# Varianza de una combinación lineal

Habíamos visto que la  $V(ax + b) = a^2V(x)$ . En el caso de un par de variables aleatorias ( $X, Y$ ) la varianza de una combinación lineal de estas variables, puede demostrarse que resulta:

$$V(ax + by + c) = a^2V(x) + b^2V(y) + 2abCOV(x, y)$$

Demostración para el caso de una VAC:

Por definición de Varianza:  $V(x) = \sigma_x^2 = E(x^2) - E(x)^2$

$$V(ax + by + c) = \underbrace{E[(ax + by + c)^2]}_{(1)} - \underbrace{[E(ax + by + c)]^2}_{(2)}$$

$$\begin{aligned} \text{Siendo (1): } E[(ax + by + c)^2] &= E[a^2x^2 + b^2y^2 + c^2 + 2(axby + byc + axc)] \\ &= a^2E(x^2) + b^2E(y^2) + c^2 + 2abE(xy) + 2bcE(y) + 2acE(x) \end{aligned}$$

$$\begin{aligned} \text{y (2): } [E(ax + by + c)]^2 &= [aE(x) + bE(y) + c]^2 \\ &= a^2 [E(x)]^2 + b^2[E(y)]^2 + c^2 + 2abE(x)E(y) + 2bcE(y) + 2acE(x) \end{aligned}$$

Por tanto: (1) - (2):

$$V(ax + by + c) = a^2E(x^2) + b^2E(y^2) + \cancel{c^2} + 2abE(xy) + 2bcE(y) + 2acE(x) \\ - a^2[E(x)]^2 - b^2[E(y)]^2 - \cancel{c^2} - 2abE(x)E(y) - 2bcE(y) - 2acE(x)$$

Agrupando términos

$$V(ax + by + c) = a^2[E(x^2) - E(x)^2] + b^2[E(y^2) - E(y)^2] + 2ab[E(xy) - E(x)E(y)] \\ \underbrace{V(x)} \qquad \qquad \qquad \underbrace{V(y)} \qquad \qquad \qquad \underbrace{COV(x, y)}$$

$$V(ax + by + c) = a^2V(x) + b^2V(y) + 2abCOV(x, y)$$